

Inteligência Artificial Generativa
From Deep Learning to Large Language Models

Lucas A. Souza

2026

Abstract

Este documento apresenta um resumo das principais ideias e conceitos da Inteligência Artificial Generativa, desde os fundamentos do Deep Learning até os modelos de linguagem (LLMs). A abordagem é baseada em estudos e implementações práticas.

Contents

I	Fundamentos	2
1	Fundamentos de Deep Learning	3
2	NLP Clássico e Representação de Texto	4
3	RNN, LSTM e GRU	5
II	Transformers e Large Language Models	6
4	Attention e Transformers	7
5	Large Language Models	8
III	RAG, Frameworks e Agentes	9
6	Embeddings, Busca Vetorial e RAG	10
7	LangChain, LangGraph e LlamaIndex	11
8	Agentes de IA	12
9	Model Context Protocol (MCP)	13
IV	Produção e Deploy	14
10	OpenAI API e Azure OpenAI	15
11	FastAPI	16

12 Docker e Deploy	17
13 Observabilidade, Avaliação e Guardrails	18

Part I

Fundamentos

Chapter 1

Fundamentos de Deep Learning

Perceptron, MLP, forward pass, backpropagation, funções de ativação, funções de perda, gradiente descendente, Adam, regularização, Dropout, BatchNorm e validação.

Chapter 2

NLP Clássico e Representação de Texto

Tokenização, n-grams, vetores de palavras (word2vec, GloVe), classificação de texto, embeddings, TF-IDF, bag of words e métricas de similaridade.

Chapter 3

RNN, LSTM e GRU

Redes recorrentes, vanishing gradient, LSTM, GRU, modelagem de sequências, geração e classificação de texto. Limitações frente aos Transformers.

Part II

Transformers e Large Language Models

Chapter 4

Attention e Transformers

Query, Key, Value, self-attention, masked attention, cross-attention, multi-head attention, positional encoding, encoder, decoder.

Chapter 5

Large Language Models

Transformers, tokenização, modelos pré-treinados, BERT, GPT, fine-tuning, prompting, RLHF e alinhamento.

Part III

RAG, Frameworks e Agentes

Chapter 6

Embeddings, Busca Vetorial e RAG

Loaders, chunking, embeddings, vector stores, retrieval, reranking, avaliação de RAG, chat com documentos.

Chapter 7

LangChain, LangGraph e LlamaIndex

Models, prompts, parsers, chains, memória, agentes, tools, workflows, ingestão, indexação, query engines.

Chapter 8

Agentes de IA

Reasoning loop, tools, actions, function calling, estados, transições, memória, human-in-the-loop, avaliação de agentes.

Chapter 9

Model Context Protocol (MCP)

Arquitetura MCP, clientes, servidores, tools, resources, prompts, SDKs e integração com agentes.

Part IV

Produção e Deploy

Chapter 10

OpenAI API e Azure OpenAI

SDK, Responses API, streaming, tools, structured outputs, RAG com Azure AI Search, busca híbrida e ranking semântico.

Chapter 11

FastAPI

Rotas, parâmetros, Pydantic, validação, dependências, segurança, autenticação, testes e aplicações modulares.

Chapter 12

Docker e Deploy

Containers, imagens, Dockerfile, volumes, redes, Docker Compose, orquestração de API e banco vetorial.

Chapter 13

Observabilidade, Avaliação e Guardrails

Tracing, latência, erros, tokens, custo, guardrails, suítes de avaliação, cache, fallback, LLMOps.